

nba_predictor

Cómo funciona el sistema, paso a paso

Estilo de equipo · construcción de plantel · fuerza real · predicción de victorias

Cada sección tiene dos niveles: una explicación sencilla (recuadro verde) y el detalle técnico debajo. Puedes leer solo los recuadros para una visión general, o todo para el detalle.

1. Qué hace el sistema

En simple. El sistema mira a cada equipo de la NBA y responde tres preguntas: ¿cómo juega? (su estilo), ¿cómo está armado? (su tipo de plantilla), y ¿qué tan bueno es de verdad? (la fuerza de sus jugadores). Con eso, predice cuántos partidos va a ganar la próxima temporada — antes de que empiece.

En detalle. nba_predictor es un pipeline reproducible que descarga datos oficiales de la NBA (equipos, jugadores, quintetos, entrenadores), los limpia, y aplica una cadena de modelos: (1) clustering de estilo de equipo, (2) clustering de construcción de plantilla a partir de arquetipos de jugador, (3) una métrica de fuerza del plantel basada en impacto individual, (4) una proyección de cada jugador desde su historia, y (5) un modelo de victorias validado con backtesting. Todo corre con un solo comando (run_all.py) y se actualiza cada temporada.

El objetivo final es una cascada completa: proyectar victorias, ordenar la tabla, simular playoffs y estimar al campeón. Este documento cubre lo ya construido y validado hasta el modelo de victorias (M1).

2. Los datos y el flujo

En simple. Bajamos cuatro cosas de la NBA: estadísticas de equipos, de jugadores, los quintetos que jugaron juntos, y quién dirigió cada equipo. Todo pasa por una limpieza y queda listo para los modelos.


En detalle. Fuentes vía nba_api: stats avanzadas de equipo (leaguedashteamstats), de jugador base+avanzadas (leaguedashplayerstats), quintetos (leaguedashlineups), standings y entrenadores (commonteamroster). Cobertura 2019-20 a 2025-26 (7 temporadas, 210 equipos-temporada, ~3.700 jugador-temporadas). El pipeline es idéntico con datos reales; la descarga corre en tu máquina y el procesamiento en cualquier lado.

Flujo: descarga → limpieza → estilo + arquetipos + fuerza → proyección → modelo de victorias → gráficas.

3. Paso 1 — Estilo de juego

En simple. Agrupamos a los equipos según cómo juegan: rápido o lento, ofensivos o defensivos, etc. Salen tres familias de estilo. Así podemos ver, por ejemplo, qué estilos suelen llegar a campeones.

En detalle. KMeans (k=3) sobre 8 features avanzadas escaladas por temporada: OFF_RATING, DEF_RATING, AST%, OREB%, DREB%, TOV%, TS%, PACE. Resultan tres estilos: 'Defensivos lentos', 'Ofensivos rápidos' y un grupo de equipos flojos. Cada equipo-temporada queda ubicado en este espacio; abajo, proyección a 2 componentes principales con campeones y finalistas etiquetados.




Espacio de estilo 2019-26. ★ = campeón. Los campeones tienden al lado derecho (buena ofensiva/eficiencia).

4. Paso 2 — Arquetipos y tipo de plantel


En simple. Primero clasificamos a cada jugador por lo que hace en cancha (anotador, creador, tirador, interior...), sin importar su posición oficial. Luego describimos a cada equipo por la mezcla de esos roles, y agrupamos equipos que se construyen parecido.

En detalle. Arquetipos: KMeans (6 grupos) sobre tasas por 36 min (puntos, asistencias, rebotes, robos, tapones, volumen de triple) más $USG\%$, $AST\%$, $REB\%$, $TS\%$. Tipo de plantel: cada equipo se representa por la fracción de minutos en cada arquetipo, y otro KMeans (4 tipos) agrupa las construcciones. Hallazgo: el tipo 'creador principal + jugadores de rol' concentra 4 de los últimos campeones — la construcción clásica de estrella rodeada de especialistas.

El mapa siguiente muestra en qué estadística resalta cada uno de los 6 arquetipos (rojo = por encima del resto, azul = por debajo): el creador tiene el uso más alto; el protector de aro, rebote y tapones; el wing, volumen de triple; y el jugador de rol, bajo en todo.



Perfil de los 6 arquetipos (z-score entre arquetipos). Rojo = la estadística en la que ese arquetipo destaca.



Espacio de tipo de plantel. ★ = campeón.

5. Paso 3 — Fuerza del plantel

En simple. Necesitamos medir qué tan bueno es de verdad cada equipo. Sumamos el impacto de sus jugadores (ponderado por los minutos que juegan). Un primer intento con otra métrica falló — no tenía relación con ganar — así que lo cambiamos por una que sí funciona.

En detalle. `squad_strength` = PIE (Player Impact Estimate) ponderado por minutos, estandarizado por temporada. Un intento previo heredado (APM del proyecto de tanking) daba correlación ~0.00 con victorias en datos reales — no servía. La métrica basada en PIE correlaciona 0.76 con las victorias y separa campeones (percentil 81 vs 52 del APM). Es la señal de talento del sistema.


¿Qué es el PIE y cómo se calcula?

En simple. El PIE mide qué porción de todo lo bueno que pasó en los partidos de un jugador la aportó él. Se suma lo positivo (puntos, canastas, rebotes, asistencias, robos, tapones) y se resta lo negativo (tiros fallados, pérdidas, faltas); ese total del jugador se divide entre el mismo total de TODOS los jugadores del partido. Un jugador promedio ronda 0.10 (10%); una estrella, 0.15-0.20.

En detalle. El PIE es una estadística avanzada oficial de la NBA: no la calculamos nosotros, la tomamos ya lista por jugador y temporada vía `nba_api` (`leaguedashplayerstats`, tipo `Advanced`). Su fórmula es un cociente entre lo que produce el jugador y lo que se produce en todo el partido (ambos equipos):

$$\begin{aligned} \text{PIE} = & (\text{PTS} + \text{FGM} + \text{FTM} - \text{FGA} - \text{FTA} + \text{DREB} + 0.5 * \text{OREB} \\ & + \text{AST} + \text{STL} + 0.5 * \text{BLK} - \text{PF} - \text{TOV}) \\ & / (\text{mismos totales sumados de TODO el partido}) \end{aligned}$$

Donde PTS=puntos, FGM/FGA=canastas anotadas/intentadas, FTM/FTA=libres, DREB/OREB=rebotes defensivos/ofensivos, AST=asistencias, STL=robo, BLK=tapones, PF=faltas, TOV=pérdidas. Como es una proporción del partido, es comparable entre jugadores y temporadas sin depender del ritmo del equipo. La fuerza del equipo (`squad_strength`) es el promedio del PIE de sus jugadores ponderado por los minutos que juega cada uno: los titulares pesan más que el fondo del banquillo.



Fuerza del plantel por equipo, temporada 2025-26.

6. Paso 4 — Proyección de cada jugador

En simple. Para predecir el futuro no podemos usar las estadísticas del año que aún no pasa. Así que a cada jugador le proyectamos lo que va a aportar usando su historia y su edad (los jóvenes mejoran, los veteranos declinan). Si es novato sin historia, usamos un valor base.

En detalle. Para cada jugador y temporada T se estima su PIE usando solo datos $< T$: promedio de sus temporadas previas ponderado por recencia, con regresión a la media para muestras chicas, y ajuste por curva de edad. Probamos dos curvas: una estimada de nuestros datos (cambio de PIE año a año por edad) y una estándar (pico ~26). Ambas superan al baseline naive (usar el PIE del año pasado sin ajuste):

Método	MAE (error)	Correlación
Naive (PIE del año pasado)	0.0176	0.697
Curva de edad de datos	0.0167	0.718
Curva de edad estándar	0.0165	0.728

Esto cubre el caso clave: un jugador que cambió de equipo o aún no jugó esta temporada recibe una proyección realista desde su trayectoria.

7. Paso 5 — Fuerza proyectada y continuidad

En simple. Juntamos las proyecciones de los jugadores de cada equipo para estimar la fuerza del plantel del año que viene, sin usar nada de ese año. También medimos cuánto del equipo se mantiene respecto al año anterior.

En detalle. $\text{squad_strength_proj}$ = PIE proyectado ponderado por minutos proyectados, agregado por equipo. continuity = fracción de minutos proyectados que vienen de jugadores que ya estaban el año anterior. Aunque es 100% pre-temporada, la fuerza proyectada correlaciona 0.61 con las victorias reales, y la continuidad 0.47. Son señales legítimas para pronosticar.

8. Paso 6 — El entrenador

En simple. Un técnico imprime su forma de jugar y suele rendir por encima o por debajo de lo que dice el talento. Extraemos su 'huella de estilo' y su historial de victorias sobre lo esperado, usando solo su pasado.

En detalle. Por equipo-temporada calculamos, con la historia del coach < T: huella de estilo (pace y lean ofensivo/defensivo típicos) y residual de rendimiento (victorias reales menos las esperadas por talento), con shrinkage. El residual identifica bien a técnicos que suman (Mazzulla, Daigneault, Atkinson). Sin embargo, al probarlo en el backtest, incluirlo en M1 EMPEORABA la predicción (subía el error) — así que, por disciplina, el entrenador NO entra en el modelo final. Es un ejemplo de una señal plausible que los datos no respaldaron; queda como candidata a reformular en el futuro.

9. Paso 7 — Modelo de victorias (M1)

En simple. Con todo lo anterior, un modelo estima cuántos partidos ganará cada equipo. Lo probamos 'como si viviéramos en el pasado': entrenamos con temporadas viejas y predecimos la siguiente, sin hacer trampa. Le gana a simplemente asumir que un equipo repetirá sus victorias del año pasado.

En detalle. M1 es una regresión Ridge sobre 5 features: `squad_strength_proj`, `continuity`, `prior_net_rating` (diferencial del año previo), `best_pie_proj` (la estrella) y `avg_age_core` (edad del núcleo). Estas se eligieron por backtest y ablación: cada una entra solo si baja el error. Validación walk-forward: para cada temporada de prueba se entrena con todas las anteriores y se predice esa.

Las 5 variables de M1, una por una

El 'peso' es cuánto empuja cada una la predicción (coeficiente estandarizado): a mayor valor absoluto, más influye; el signo indica si suma o resta victorias.

Variable	Qué es (en simple)	Cómo se calcula (técnico)	Peso
continuity (continuidad)	Cuánto del equipo se mantiene respecto al año pasado. Los equipos que conservan su núcleo rinden de forma más estable.	Fracción de los minutos proyectados que aportan jugadores que ya estaban en el equipo la temporada anterior (0 a 1).	+4 . 4
prior_net_rating (diferencial previo)	El diferencial de puntos del año pasado. Predice mejor el futuro que el récord de victorias (tiene menos ruido de suerte).	NET_RATING de la temporada T-1 del mismo equipo.	+2 . 7
avg_age_core (edad del núcleo)	La edad promedio de la rotación. Un núcleo más asentado tiende a ganar más; los muy jóvenes aún están desarrollándose.	Edad media de los 8 con más minutos proyectados, ponderada por minutos.	+2 . 3
squad_strength_proj (fuerza proyectada)	Qué tan bueno se espera que sea el equipo por el talento de sus jugadores, estimado desde su historia — sin mirar el año en curso.	PIE proyectado de cada jugador (edad + recencia + trayectoria) ponderado por minutos, estandarizado por temporada.	+2 . 1
best_pie_proj (la estrella)	El nivel del mejor jugador. En la NBA el techo lo marca la superestrella, que la fuerza promedio diluye entre 8-10 jugadores.	PIE proyectado del jugador más impactante del plantel.	+1 . 8


Lectura: la continuidad y el diferencial previo pesan fuerte, y la fuerza del plantel se reparte entre el promedio y la estrella. El entrenador se probó pero se descartó porque empeoraba el backtest (ver sección 8).

¿Qué es el MAE de victorias?

En simple. El MAE (error absoluto medio) es cuántas victorias, en promedio, se equivoca la predicción. Un MAE de 7.0 significa que, en promedio, el número predicho se aleja del real unas 7 victorias — hacia arriba o hacia abajo. Cuanto más bajo, mejor. Ejemplo: si predecimos 48 victorias y el equipo gana 45, ese error es de 3.

En detalle. MAE = promedio de $|victorias_predichas - victorias_reales|$ sobre todos los equipos de prueba. Se prefiere al error cuadrático porque está en las mismas unidades (victorias) y es fácil de interpretar. Comparamos el MAE del modelo contra dos referencias: asumir que el equipo repetirá sus victorias del año pasado (8.89) y asumir la media de la liga (~10.7). M1 logra 7.02, mejor que ambas en todas las temporadas.

Temporada	MAE M1	MAE 'año pasado'	Correlación M1
2021-22	7.99	8.33	0.549
2022-23	5.77	8.07	0.738
2023-24	6.21	8.47	0.819
2024-25	7.20	9.13	0.728
2025-26	7.93	10.43	0.682
GLOBAL	7.02	8.89	0.693



Predicho vs real (walk-forward). El modelo acierta la tendencia y comprime los extremos, típico de un modelo pre-temporada.

10. Qué usa y qué no (sin trampa)


En simple. Para predecir una temporada, el modelo NUNCA mira los resultados de esa temporada (ni victorias ni estadísticas de ese año). Solo usa el pasado: la historia de los jugadores, las victorias del año anterior y el historial del entrenador. Lo único del año en curso que usa es quién está en cada equipo (el roster), que es información que sí se conoce antes de empezar.

En detalle. Sin fuga de rendimiento: `squad_strength_proj` y `best_pie_proj` se construyen con PIE proyectado de temporadas $< T$; `prior_net_rating` es de $T-1$; `avg_age_core` es conocido antes de empezar. Matices honestos: (a) el roster de T se tomó de datos reales, así que incluye traspasos de media temporada — para el backtest es una suposición razonable, y para la predicción viva de 2026-27 se resuelve dando el roster conocido antes de empezar; (b) los minutos de novatos usan un placeholder — es una fuga menor a corregir. Nada de esto toca el resultado que se predice.

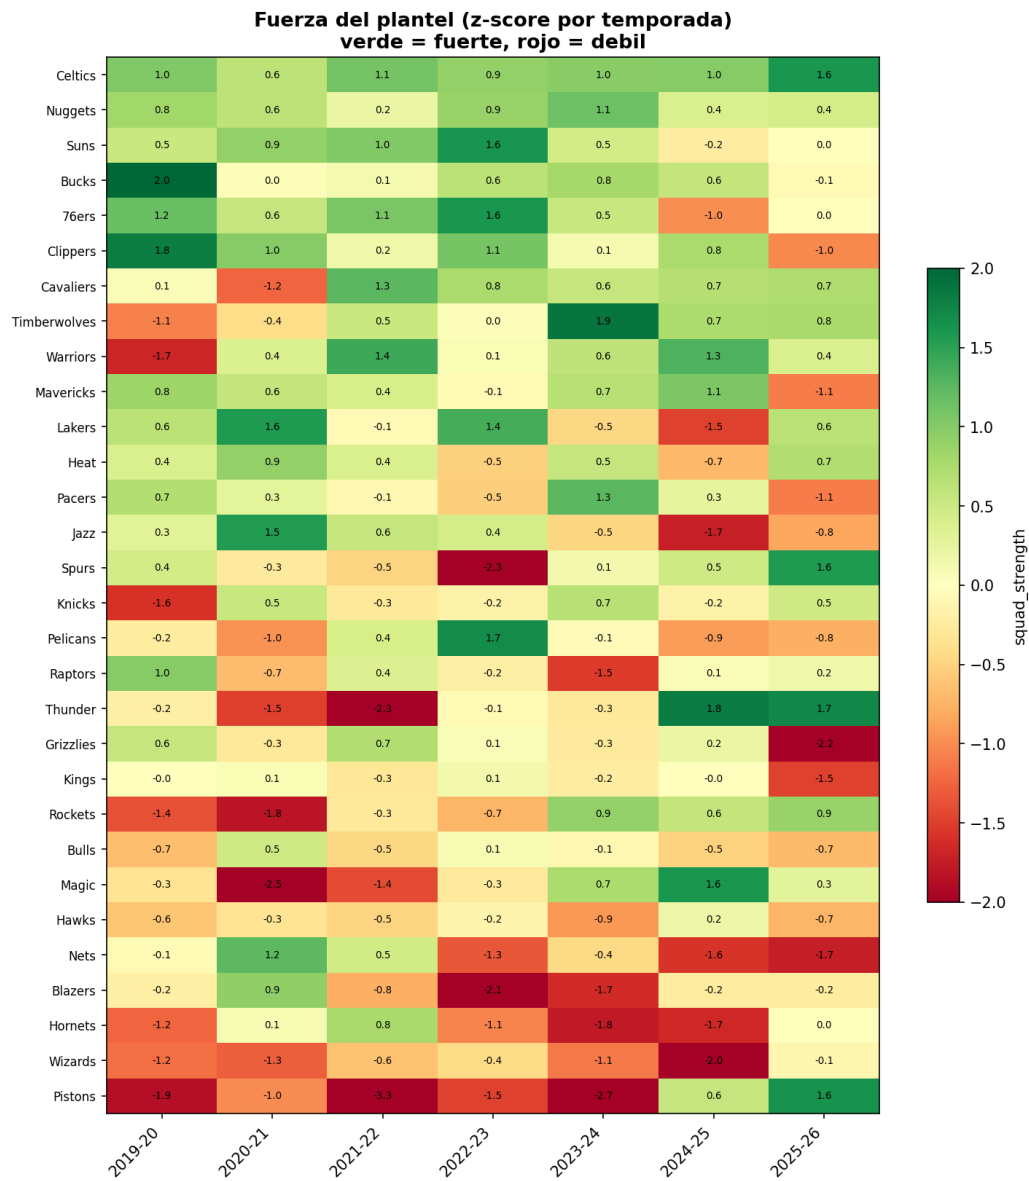
11. Fuerza vs. parecido a campeones

En simple. Combinamos dos ideas: qué tan fuerte es un plantel y qué tanto se parece su estilo al de los campeones históricos. Los equipos arriba-derecha son los que tienen las dos cosas.

En detalle. La proximidad a campeón es la distancia del estilo de un equipo al centroide de los campeones en el espacio de 8 features. El mapa de contendientes cruza esa proximidad con la fuerza del plantel para la temporada actual. Nota: usa el estilo realizado de 2025-26, así que es descriptivo del año, no un pronóstico puro — pero valida el enfoque: el campeón real (Knicks) aparece arriba-derecha.



Mapa de contendientes 2025-26. Arriba-derecha: fuertes y con estilo de campeón (Spurs, Thunder, Cavaliers, Knicks, Celtics).



Fuerza del plantel de cada equipo a lo largo de las temporadas (verde = fuerte).

12. Cómo se actualiza y qué sigue

En simple. Cada año se bajan los datos nuevos, se corre un comando, y todo se recalcula solo — incluidas las gráficas. La cascada completa (victorias, seeding, playoffs y campeón) ya está construida.

En detalle. Actualización anual: descargar la temporada nueva (download_teams/players/lineups/coaches), correr run_all.py, y añadir el campeón en champions.py. La cascada M1-M4 está lista y validada. Próximos pasos del roadmap: predicción partido a partido con el calendario, mejor proyección de minutos, y actualización en vivo (Elo) para capturar lesiones y forma durante el año. Métrica actual: MAE 7.02 victorias, mejor que la persistencia (8.89); acierto por partido ~63%.

Archivos clave: run_all.py (pipeline), PLAN.md y PREDICTOR_DESIGN.md (diseño), outputs/ (tablas y figuras).